

# PRML 3 線形回帰モデル

大阪 PRML 読書会

2014 年 8 月 31 日

# 目次

## 3 線形回帰モデル

### 導入

#### 3.1 線形基底関数モデル

3.1.1 最尤推定と最小二乗法

3.1.2 最小二乗法の幾何学

3.1.3 逐次学習

3.1.4 正則化最小二乗法

3.1.5 出力変数が多次元の場合

# 導入

## 回帰問題に対する二つのアプローチ

- ▶ 予測関数  $y(\mathbf{x})$  を構成する。
- ▶ 条件付き確率分布関数  $p(t|\mathbf{x})$  を構成する。  
その分布の下で期待損失を最小化するように  $\mathbf{x}$  に対する  $t$  を決定する。

# 線形基底関数モデル

一般形

$$\begin{aligned}y(\mathbf{x}, \mathbf{w}) &= w_0 + \sum_{j=1}^{M-1} w_j \phi_j(\mathbf{x}) \\&= \sum_{j=0}^{M-1} w_j \phi_j(\mathbf{x}) \\&= \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})\end{aligned}$$




where  $\phi_j(\mathbf{x})$  : 基底関数

$\phi_0(\mathbf{x}) = 1$  : ダミーの基底関数

$$\boldsymbol{\phi} = (\phi_0, \dots, \phi_{M-1})^T$$

$$\mathbf{w} = (w_0, \dots, w_{M-1})^T$$

# 線形基底関数モデル



# 最尤推定と最小二乗法

目標変数  $t$  が、決定論的な関数  $y(\mathbf{x}, \mathbf{w})$  とガウスノイズの和で与えられると仮定する。

$$t = y(\mathbf{x}, \mathbf{w}) + \epsilon \quad \text{where} \quad p(\epsilon|\beta) = \mathcal{N}(\epsilon|0, \beta^{-1})$$

これは以下と等価である。

$$p(t|\mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t|y(\mathbf{x}, \mathbf{w}), \beta^{-1})$$

# 最尤推定と最小二乗法

## 決定段階

損失関数として二乗損失関数を仮定すると、新しい  $\mathbf{x}$  の値に対する最適な予測値は目標変数の条件付き期待値で与えられる。

$$t = \mathbb{E}[t|\mathbf{x}] = \int tp(t|\mathbf{x})dt$$

先に仮定した条件付き確率分布を用いると、

$$\begin{aligned} t &= \int t\mathcal{N}(t|y(\mathbf{x}, \mathbf{w}), \beta^{-1})dt \\ &= y(\mathbf{x}, \mathbf{w}) \end{aligned}$$

$t$  は決定論的関数の値として与えられる。

# 最尤推定と最小二乗法

データ集合

$$\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_N)^T$$
$$\mathbf{t} = (t_1, \dots, t_N)^T$$

尤度関数

$$p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n), \beta^{-1})$$



# 最尤推定と最小二乗法

対数尤度関数

$$\begin{aligned}\ln p(\mathbf{t}|\mathbf{w}, \beta) &= \sum_{n=1}^N \ln \mathcal{N}(t_n | \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n), \beta^{-1}) \\ &= \sum_{n=1}^N \ln \left[ \left( \frac{\beta}{2\pi} \right)^{1/2} \exp \left\{ -\frac{\beta}{2} (t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n))^2 \right\} \right] \\ &= \frac{N}{2} \ln \beta - \frac{N}{2} \ln 2\pi - \beta E_D(\mathbf{w})\end{aligned}$$

ただし

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2$$

$E_D$  は二乗和誤差関数。

# 最尤推定と最小二乗法

$\mathbf{w}$  の最尤推定

$$\begin{aligned}\nabla \ln p(\mathbf{t}|\mathbf{w}, \beta) &= \beta \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\} \boldsymbol{\phi}(\mathbf{x}_n)^T \\ 0 &= \sum_{n=1}^N t_n \boldsymbol{\phi}(\mathbf{x}_n)^T - \mathbf{w}_{\text{ML}}^T \left( \sum_{n=1}^N \boldsymbol{\phi}(\mathbf{x}_n) \boldsymbol{\phi}(\mathbf{x}_n)^T \right)\end{aligned}$$

$$0 = \boldsymbol{\Phi}^T \mathbf{t} - \mathbf{w}_{\text{ML}}^T (\boldsymbol{\Phi}^T \boldsymbol{\Phi})$$

$$\mathbf{w}_{\text{ML}} = (\boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T \mathbf{t} = \boldsymbol{\Phi}^\dagger \mathbf{t} \quad \dots \text{正規方程式}$$

ただし、 $\boldsymbol{\Phi}$  は計画行列 design matrix。

$$\boldsymbol{\Phi} = \begin{pmatrix} \boldsymbol{\phi}(\mathbf{x}_1)^T \\ \boldsymbol{\phi}(\mathbf{x}_2)^T \\ \vdots \\ \boldsymbol{\phi}(\mathbf{x}_N)^T \end{pmatrix} = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{pmatrix}$$

# 最尤推定と最小二乗法

バイアスパラメータ  $w_0$  の役割

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \left\{ t_n - w_0 - \sum_{j=1}^{M-1} w_j \phi_j(\mathbf{x}_n) \right\}^2$$

$$\frac{\partial}{\partial w_0} E_D(\mathbf{w}) = - \sum_{n=1}^N \left\{ t_n - w_0 - \sum_{j=1}^{M-1} w_j \phi_j(\mathbf{x}_n) \right\}$$

$$w_0^{\text{ML}} = \bar{t} - \sum_{j=1}^{M-1} w_j^{\text{ML}} \overline{\phi_j}$$

$$\bar{t} = \frac{1}{N} \sum_{n=1}^N t_n$$

目標値の訓練集合に関する平均

$$\overline{\phi_j} = \frac{1}{N} \sum_{n=1}^N \phi_j(\mathbf{x}_n)$$

基底関数の値の訓練集合に関する平均

# 最尤推定と最小二乗法

$\beta$  の最尤推定

$$\begin{aligned}\frac{\partial}{\partial \beta} \ln p(\mathbf{t}|\mathbf{w}, \beta) &= \frac{\partial}{\partial \beta} \left\{ \frac{N}{2} \ln \beta - \frac{N}{2} \ln 2\pi - \beta E_D(\mathbf{w}) \right\} \\ &= \frac{N}{2} \frac{1}{\beta} - E_D(\mathbf{w})\end{aligned}$$

$$\frac{N}{2} \frac{1}{\beta_{\text{ML}}} - E_D(\mathbf{w}_{\text{ML}}) = 0$$

$$\frac{1}{\beta_{\text{ML}}} = \frac{1}{N} \sum_{n=1}^N \{t_n - \mathbf{w}_{\text{ML}}^T \phi(\mathbf{x}_n)\}^2$$

ノイズの精度の逆数は、  
回帰関数周りでの目標値の残差分散で与えられる。

# 最小二乗法の幾何学

各軸が  $t_n$  で与えられる  $N$  次元空間。

$$\mathbf{t} = (t_1, \dots, t_N)^T$$

訓練データ集合の目標値の集合。

$$\boldsymbol{\varphi}_j = (\phi_j(\mathbf{x}_1), \dots, \phi_j(\mathbf{x}_N))^T$$

訓練データ集合の基底関数の値の集合。

$\boldsymbol{\varphi}_j$  は  $\Phi$  の列ベクトル。 $\phi(\mathbf{x}_n)^T$  は行ベクトル。

$M$  個の  $\boldsymbol{\varphi}_j$  は  $M$  次元の線形部分空間  $\mathcal{S}$  を張る。


$$\mathbf{y} = (y(\mathbf{x}_1, \mathbf{w}), \dots, y(\mathbf{x}_N, \mathbf{w}))^T$$

目標値の予測値の集合。

$\mathbf{y}$  は  $\boldsymbol{\varphi}_j$  の線形結合なので  $\mathcal{S}$  上にある。

$$\begin{aligned}\mathbf{y} &= (\phi(\mathbf{x}_1)^T \mathbf{w}, \dots, \phi(\mathbf{x}_N)^T \mathbf{w})^T \\ &= (\phi(\mathbf{x}_1)^T, \dots, \phi(\mathbf{x}_N)^T)^T \mathbf{w} \\ &= \Phi \mathbf{w} \\ &= (\boldsymbol{\varphi}_0, \dots, \boldsymbol{\varphi}_{M-1}) \mathbf{w}\end{aligned}$$

# 最小二乗法の幾何学



$$\sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 = \|\mathbf{t} - \mathbf{y}\|^2$$

## 演習 3.2

[定義]  $\mathbf{v}'$  が  $\mathbf{v}$  の  $\mathcal{S}$  への正射影である。

ただし、 $\mathcal{S}$  は基底ベクトル  $\{\mathbf{e}_j\}$  が張る空間。

$\mathbf{A} = (\mathbf{e}_1, \dots, \mathbf{e}_M)$ 。

1.  $\mathbf{v}'$  が  $\mathcal{S}$  上にある。

$$\exists \mathbf{w}. \mathbf{v}' = \sum_j \mathbf{e}_j w_j \Leftrightarrow \mathbf{w}. \mathbf{v}' = \mathbf{A} \mathbf{w}$$

2.  $\mathbf{v} - \mathbf{v}'$  が  $\mathcal{S}$  と直交する。

$$\forall j. \mathbf{e}_j(\mathbf{v} - \mathbf{v}') = 0 \Leftrightarrow \mathbf{A}^T(\mathbf{v} - \mathbf{v}') = 0$$

$\mathbf{v}' = \Phi(\Phi^T \Phi)^{-1} \Phi^T \mathbf{v}$  と置く。

1.  $\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{v}$  と置けばただちに成り立つ。

$$\begin{aligned} 2. \quad \Phi^T(\mathbf{v} - \mathbf{v}') &= \Phi^T(\mathbf{v} - \Phi(\Phi^T \Phi)^{-1} \Phi^T \mathbf{v}) \\ &= (\Phi^T - \Phi^T \Phi (\Phi^T \Phi)^{-1} \Phi^T) \mathbf{v} \\ &= (\Phi^T - \Phi^T) \mathbf{v} \\ &= 0 \end{aligned}$$

## 演習 3.2

$y$  の定義より

$$y = \Phi w$$

$w$  の最小二乗解は正規方程式 (3.15) により

$$w_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T t$$

$y$  の最小二乗解は

$$y_{\text{ML}} = \Phi (\Phi^T \Phi)^{-1} \Phi^T t$$

よって、 $y$  の最小二乗解は  
 $t$  の  $\Phi$  の列ベクトルが張る多様体  $\mathcal{S}$  への正射影である。



# 逐次学習

確率的勾配降下法 stochastic gradient descent

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_n$$

二乗和誤差関数

$$E_n(\mathbf{w}) = \frac{1}{2} (t_n - \mathbf{w}^T \phi(\mathbf{x}_n))^2$$

を用いると

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} + \eta (t_n - \mathbf{w}^{(\tau)T} \phi(\mathbf{x}_n)) \phi(\mathbf{x}_n)$$

最小平均二乗アルゴリズム

least-mean-squares (LMS) algorithm

# 正則化最小二乗法

正則化された誤差関数

$$E_D(\mathbf{w}) + \lambda E_W(\mathbf{w})$$

$E_D(\mathbf{w})$  : データに依存する誤差

$E_W(\mathbf{w})$  : 正則化項

二乗和誤差関数 + 二次正則化項

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

最小化

$$\mathbf{w} = (\lambda \mathbf{I} + \Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

# 正則化最小二乗法





## 誤差関数の最小化

$$\begin{aligned} & \nabla \left[ \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \mathbf{w}^T \mathbf{w} \right] \\ &= -\boldsymbol{\Phi}^T \mathbf{t} + \mathbf{w}^T \boldsymbol{\Phi}^T \boldsymbol{\Phi} + \lambda \mathbf{w}^T \\ &= -\boldsymbol{\Phi}^T \mathbf{t} + \mathbf{w}^T \boldsymbol{\Phi}^T \boldsymbol{\Phi} + \mathbf{w}^T (\lambda \mathbf{I}) \\ &= -\boldsymbol{\Phi}^T \mathbf{t} + \mathbf{w}^T (\lambda \mathbf{I} + \boldsymbol{\Phi}^T \boldsymbol{\Phi}) \end{aligned}$$


# 正則化最小二乘法

二乗和誤差関数 +  $q$  次正則化項

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q$$



# 正則化最小二乘法



## 演習 3.5

制約条件 (3.30) は以下のように書き換えられる。

$$\sum_{j=1}^M |w_j|^q \leq \eta \Leftrightarrow -\frac{1}{2} \left( \sum_{j=1}^M |w_j|^q - \eta \right) \geq 0$$

ラグランジュ関数

$$L(\mathbf{w}, \lambda) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \left( \sum_{j=1}^M |w_j|^q - \eta \right)$$

where  $g(\mathbf{w}) \geq 0 \quad \lambda \geq 0 \quad \lambda g(\mathbf{w}) = 0$

停留条件

$\nabla L(\mathbf{w}, \lambda) = 0 \rightarrow$  正則化された誤差関数の最小化と同じ

$$\frac{\partial}{\partial \lambda} L(\mathbf{w}, \lambda) = 0 \rightarrow \eta = \sum_{j=1}^M |w_j|^q = \sum_{j=1}^M |w_j(\lambda)|^q$$

# 出力変数が多次元の場合

$\mathbf{t}$  のすべての要素に同じ基底関数を用いたモデル

$$y(\mathbf{x}, \mathbf{w}) = \mathbf{W}^T \phi(\mathbf{x})$$

$\mathbf{t}$  の条件付き分布を等方性ガウス分布と仮定する。

$$p(\mathbf{t}|\mathbf{x}, \mathbf{W}, \beta) = \mathcal{N}(\mathbf{t}|\mathbf{W}^T \phi(\mathbf{x}), \beta^{-1} \mathbf{I})$$

## 出力変数が多次元の場合

データ集合  $\mathbf{T} = (\mathbf{t}_1, \dots, \mathbf{t}_N)^T$ 、 $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_N)^T$

対数尤度関数

$$\begin{aligned} & \ln p(\mathbf{T}|\mathbf{X}, \mathbf{W}, \beta) \\ &= \sum_{n=1}^N \ln \mathcal{N}(\mathbf{t}_n | \mathbf{W}^T \boldsymbol{\phi}(\mathbf{x}_n), \beta^{-1} \mathbf{I}) \\ &= \sum_{n=1}^N \ln \left[ \left( \frac{\beta}{2\pi} \right)^{K/2} \exp \left\{ -\frac{\beta}{2} \|\mathbf{t}_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\|^2 \right\} \right] \\ &= \frac{NK}{2} \ln \left( \frac{\beta}{2\pi} \right) - \frac{\beta}{2} \sum_{n=1}^N \|\mathbf{t}_n - \mathbf{W}^T \boldsymbol{\phi}(\mathbf{x}_n)\|^2 \end{aligned}$$

最尤解

$$\mathbf{W}_{\text{ML}} = (\boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T \mathbf{T} = \boldsymbol{\Phi}^\dagger \mathbf{T}$$

$$\mathbf{w}_k = (\boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T \mathbf{t}_k = \boldsymbol{\Phi}^\dagger \mathbf{t}_k$$